Sesión 4

Word Embeddings: Word2Vec y GloVe

Carlos César Sánchez Coronel

NLP

Contenido

1. Limitaciones de Representaciones Dispersas
2. Word Embeddings
3. Word2Vec
4. GloVe
5. Propiedades de los Embeddings
6. Embeddings Contextuales
7. Caso Integrado: Entrenamiento con Gensim
8. Preparación para Entrevistas
9. Conexión con el resto del curso
10. Resumen

Contenido

1. Limitaciones de Representaciones Dispersas
2. Word Embeddings
3. Word2Vec
4. GloVe
5. Propiedades de los Embeddings
6. Embeddings Contextuales
7. Caso Integrado: Entrenamiento con Gensim
8. Preparación para Entrevistas
9. Conexión con el resto del curso
10. Resumen

Problemas de BOW y TF-IDF

- **Alta dimensionalidad**: vocabulario de miles/millones de términos.
- **Esparsidad**: la mayoría de entradas son cero.
- **Falta de semántica**: "gato" y "felino" son independientes.
- **Pérdida de relaciones**: no capturan analogías (rey - hombre + mujer $\approx$ reina).
- **LSA** (Latent Semantic Analysis) intenta reducir dimensionalidad, pero es lineal y limitado.

Contenido

1. Limitaciones de Representaciones Dispersas
2. Word Embeddings
3. Word2Vec
4. GloVe
5. Propiedades de los Embeddings
6. Embeddings Contextuales
7. Caso Integrado: Entrenamiento con Gensim
8. Preparación para Entrevistas
9. Conexión con el resto del curso
10. Resumen

Definición

Word Embedding

Representación densa de palabras en un espacio vectorial continuo de baja dimensión (típicamente 50-300).

- **Hipótesis distribucional** (Harris 1954): "palabras que ocurren en contextos similares tienen significados similares".
- Las relaciones semánticas se reflejan como operaciones vectoriales.

Contenido

1. Limitaciones de Representaciones Dispersas
2. Word Embeddings
3. Word2Vec
4. GloVe
5. Propiedades de los Embeddings
6. Embeddings Contextuales
7. Caso Integrado: Entrenamiento con Gensim
8. Preparación para Entrevistas
9. Conexión con el resto del curso
10. Resumen

Arquitecturas de Word2Vec

CBOW (Continuous Bag of Words)

- Predice la palabra objetivo a partir del contexto.
- Más rápido, mejor para palabras frecuentes.

Skip-gram

- Predice el contexto a partir de la palabra objetivo.
- Mejor para palabras poco frecuentes.

CBOW: formalización

Objetivo

Dado un contexto de C palabras $\{w_{c1}, \ldots, w_{cC}\}$, maximizar $P(w_t|\text{contexto})$.

1. Embeddings de contexto: $\mathbf{v}_{c_i} = W[w_{c_i}]$.
2. Promedio: $\mathbf{h} = \frac{1}{C}\sum \mathbf{v}_{c_i}$.
3. Puntuaciones: $\mathbf{u} = \mathbf{h}^T W'$.
4. Softmax: $P(w_t|\text{contexto}) = \frac{\exp(u_t)}{\sum_k \exp(u_k)}$.

Pérdida: entropía cruzada negativa $-\log P(w_t|\text{contexto})$.

Skip-gram y negative sampling

Skip-gram

Para una palabra objetivo w_t, maximizar $P(w_c|w_t)$ para cada contexto w_c.

Negative Sampling (aproximación)

Para un par (w_t, w_c):

$$L = -\log \sigma(\mathbf{v}_{w_t}^T \mathbf{u}_{w_c}) - \sum_{i=1}^{k} \log \sigma(-\mathbf{v}_{w_t}^T \mathbf{u}_{w_{n_i}})$$

donde σ es sigmoide, w_{n_i} son palabras negativas muestreadas.

- Evita el costoso softmax sobre todo el vocabulario.
- Distribución de ruido: $P_n(w) \propto \text{freq}(w)^{3/4}$.

Comparación CBOW vs Skip-gram

Característica	**CBOW**	**Skip-gram**
Dirección	Contexto $\rightarrow$ Objetivo	Objetivo $\rightarrow$ Contexto
Velocidad	Más rápida	Más lenta
Palabras frecuentes	Bueno	Bueno
Palabras poco frecuentes	Regular	Excelente
Uso típico	Corpus grandes, eficiencia	Corpus pequeños, palabras raras

Contenido

1. Limitaciones de Representaciones Dispersas
2. Word Embeddings
3. Word2Vec
4. GloVe
5. Propiedades de los Embeddings
6. Embeddings Contextuales
7. Caso Integrado: Entrenamiento con Gensim
8. Preparación para Entrevistas
9. Conexión con el resto del curso
10. Resumen

GloVe: fundamento

Matriz de co-ocurrencia

X_{ij} = número de veces que la palabra j aparece en el contexto de i (ventana fija).

Hipótesis

$$\mathbf{v}_i^T \mathbf{v}_j + b_i + b_j \approx \log X_{ij}$$

donde $\mathbf{v}_i$, $\mathbf{v}_j$ son embeddings y b_i, b_j sesgos.

Función de pérdida de GloVe

$$\mathcal{L} = \sum_{i,j=1}^{|V|} f(X_{ij})(\mathbf{v}_i^T \mathbf{v}_j + b_i + b_j - \log X_{ij})^2$$

Función de ponderación f

$$f(x) = \begin{cases} (x/x_{\text{máx}})^{\alpha} & \text{si } x < x_{\text{máx}} \\ 1 & \text{en otro caso} \end{cases}$$

($x_{\text{máx}} = 100$, $\alpha = 0{,}75$) para dar menos peso a co-ocurrencias muy raras o muy frecuentes.

Ventajas de GloVe

- Aprovecha estadísticas globales del corpus (matriz de co-ocurrencia).
- Buenas propiedades en tareas de analogía.
- Entrenamiento eficiente (procesa pares no nulos).

Contenido

1. Limitaciones de Representaciones Dispersas
2. Word Embeddings
3. Word2Vec
4. GloVe
5. Propiedades de los Embeddings
6. Embeddings Contextuales
7. Caso Integrado: Entrenamiento con Gensim
8. Preparación para Entrevistas
9. Conexión con el resto del curso
10. Resumen

Relaciones semánticas y sintácticas

Analogías

$$\mathbf{v}_{\text{rey}} - \mathbf{v}_{\text{hombre}} + \mathbf{v}_{\text{mujer}} \approx \mathbf{v}_{\text{reina}}$$

Otros ejemplos:

- Madrid - España + Francia $\approx$ París
- caminar - camino + nado $\approx$ nadar

Evaluación intrínseca de embeddings

- **Conjuntos de analogías**: Google Analogies Dataset (semánticas y sintácticas).
- Se mide la precisión con que el modelo predice la palabra correcta mediante operaciones vectoriales.
- Otras evaluaciones: similitud de palabras (WordSim-353), etc.

Visualización con t-SNE

- t-SNE reduce embeddings a 2D preservando la estructura local.
- Palabras semánticamente similares aparecen agrupadas.
- Precaución: las distancias globales no son interpretables.

Contenido

1. Limitaciones de Representaciones Dispersas
2. Word Embeddings
3. Word2Vec
4. GloVe
5. Propiedades de los Embeddings
6. Embeddings Contextuales
7. Caso Integrado: Entrenamiento con Gensim
8. Preparación para Entrevistas
9. Conexión con el resto del curso
10. Resumen

Estáticos vs Contextuales

Estáticos

- Un vector por palabra (Word2Vec, GloVe).
- No resuelven polisemia ("banco" = mismo vector).

Contextuales

- Vector depende del contexto (ELMo, BERT, GPT).
- Diferentes sentidos tienen diferentes representaciones.

Contenido

1. Limitaciones de Representaciones Dispersas
2. Word Embeddings
3. Word2Vec
4. GloVe
5. Propiedades de los Embeddings
6. Embeddings Contextuales
7. Caso Integrado: Entrenamiento con Gensim
8. Preparación para Entrevistas
9. Conexión con el resto del curso
10. Resumen

Paso 1: Preprocesamiento

```
from gensim.models import Word2Vec
from nltk.tokenize import word_tokenize
import nltk
nltk.download('punkt')

sentences = [
    "el gato persigue al rat n",
    "el perro persigue al gato",
    "el rat n huye del gato"
]
tokenized = [word_tokenize(s.lower()) for s in sentences]
```

Paso 2: Entrenar Word2Vec

```
model = Word2Vec(
    sentences=tokenized,
    vector_size=100,
    window=5,
    min_count=1,
    workers=4,
    sg=1  # 1 para Skip-gram, 0 para CBOW
)
```

Paso 3: Explorar embeddings

```
# Embedding de una palabra
vector_gato = model.wv['gato']

# Palabras m s similares
model.wv.most_similar('gato', topn=5)

# Analog as: rey - hombre + mujer = ?
result = model.wv.most_similar(positive=['mujer', 'rey'],
                               negative=['hombre'])
```

Paso 4: Visualización con t-SNE

```
from sklearn.manifold import TSNE
import matplotlib.pyplot as plt

words = list(model.wv.index_to_key)[:100]
vectors = [model.wv[word] for word in words]

tsne = TSNE(n_components=2, random_state=42)
vectors_2d = tsne.fit_transform(vectors)

plt.figure(figsize=(12,8))
for i, word in enumerate(words):
    plt.scatter(vectors_2d[i,0], vectors_2d[i,1])
    plt.annotate(word, (vectors_2d[i,0], vectors_2d[i,1]))
plt.show()
```

Paso 5: Cargar GloVe pre-entrenado

```
from gensim.scripts.glove2word2vec import glove2word2vec
from gensim.models import KeyedVectors

glove2word2vec('glove.6B.100d.txt', 'glove.6B.100d.word2vec.txt')
glove = KeyedVectors.load_word2vec_format('glove.6B.100d.word2vec.txt')
```

Contenido

1. Limitaciones de Representaciones Dispersas
2. Word Embeddings
3. Word2Vec
4. GloVe
5. Propiedades de los Embeddings
6. Embeddings Contextuales
7. Caso Integrado: Entrenamiento con Gensim
8. Preparación para Entrevistas
9. Conexión con el resto del curso
10. Resumen

Preguntas típicas

- ¿Qué son los word embeddings y por qué son mejores que BOW/TF-IDF?
- Explica CBOW y Skip-gram. ¿Cuándo usarías cada uno?
- ¿Qué es negative sampling y por qué es necesario?
- ¿Cómo capturan relaciones semánticas los embeddings? (analogías)
- Diferencia entre Word2Vec y GloVe.
- ¿Qué son los embeddings contextuales? ¿En qué mejoran a los estáticos?

Preguntas avanzadas

- ¿Cómo funciona la función de pérdida de GloVe?
- ¿Qué es OOV y cómo lo manejan FastText o subword embeddings?
- ¿Cómo detectar y mitigar sesgos en embeddings?
- ¿Cómo evaluarías la calidad de embeddings? (intrínseca vs extrínseca)

Contenido

1. Limitaciones de Representaciones Dispersas
2. Word Embeddings
3. Word2Vec
4. GloVe
5. Propiedades de los Embeddings
6. Embeddings Contextuales
7. Caso Integrado: Entrenamiento con Gensim
8. Preparación para Entrevistas
9. Conexión con el resto del curso
10. Resumen

Próximos pasos

- **Sesión 5**: Clasificación de textos con embeddings.
- **Sesión 6**: Modelos secuenciales (RNN, LSTM) que usan embeddings.
- **Sesión 7**: Transformers (BERT) que generan embeddings contextuales.

Contenido

1. Limitaciones de Representaciones Dispersas
2. Word Embeddings
3. Word2Vec
4. GloVe
5. Propiedades de los Embeddings
6. Embeddings Contextuales
7. Caso Integrado: Entrenamiento con Gensim
8. Preparación para Entrevistas
9. Conexión con el resto del curso
10. Resumen

Lo que hemos aprendido

Conceptos clave

- **Limitaciones de representaciones dispersas**: alta dimensionalidad, falta de semántica.
- **Word2Vec**: CBOW (contexto $\rightarrow$ palabra) y Skip-gram (palabra $\rightarrow$ contexto). Negative sampling.
- **GloVe**: factorización de matriz de co-ocurrencia global.
- **Propiedades**: analogías vectoriales, evaluación intrínseca, visualización t-SNE.
- **Embeddings contextuales**: solucionan polisemia (BERT, ELMo).
- **Caso práctico**: entrenamiento y exploración con Gensim.
- **Sesgos**: detección y mitigación.

¡Gracias!